

Predicción de la deserción escolar mediante Multilayer Perceptron (MLP) y Self-Attention

Janeth Castillo
Universidad San Francisco de Quito

Julio de 2026

Resumen

Este trabajo compara un modelo Multi-Layer Perceptron (MLP) con una arquitectura que incorpora Self-Attention entre variables para predecir el abandono escolar a partir de datos tabulares. La ejecución final utilizó 500.000 registros, de los cuales 15.700 correspondieron a abandono (3,14 %). Se aplicaron división estratificada, preprocesamiento ajustado solo con entrenamiento, ponderación de clases, parada temprana y selección del umbral mediante validación. La MLP alcanzó PR-AUC de 0,8064 y F1 de 0,7900, mientras que el modelo con Self-Attention obtuvo 0,8036 y 0,7862, respectivamente. La MLP presentó mejor recall y menos falsos negativos, por lo que fue seleccionada como modelo preferido. Aunque ambos modelos discriminan adecuadamente la clase minoritaria, la MLP todavía omite cerca del 23 % de los abandonos. Por ello, los resultados requieren validación temporal, calibración y revisión por subgrupos antes de considerar una aplicación operativa.

1. Introducción

La deserción escolar es un problema de clasificación en el que interesa identificar oportunamente a estudiantes con riesgo de abandono. Una predicción temprana puede apoyar la priorización de acompañamiento académico o psicosocial, pero también puede producir daños si se interpreta como una decisión automática o causal.

El conjunto analizado presenta un fuerte desbalance: aproximadamente tres de cada cien registros pertenecen a la clase positiva. En estas condiciones, un modelo que siempre predijera “no abandono” alcanzaría 96,86 % de exactitud sin detectar un solo caso de abandono. Por ello, la evaluación se centra en precisión, recall, F1 y el área bajo la curva precisión-recall (PR-AUC), considerada especialmente informativa en problemas desbalanceados.

La pregunta de investigación es: *¿la incorporación de Self-Attention entre las variables mejora la predicción del abandono respecto de una MLP convencional?* Se plantea como hipótesis que Self-Attention podría modelar interacciones entre factores académicos, demográficos y contextuales. Sin embargo, una arquitectura más compleja solo se justifica si produce una mejora medible y consistente.

2. Trabajos relacionados

Los modelos Multilayer Perceptron constituyen una línea base flexible para datos tabulares, pues aproximan relaciones no lineales mediante capas sucesivas. Los mecanismos de atención permiten que una representación asigne distintos pesos a otras representaciones durante el procesamiento. Self-Attention se popularizó en el modelo Transformer y posteriormente se adaptó al aprendizaje tabular mediante arquitecturas como TabNet.

Self-Attention también puede ofrecer una descripción de las interacciones internas del modelo. No obstante, un peso alto no demuestra importancia causal ni garantiza

una explicación fiel de la predicción. En este trabajo se utiliza como recurso descriptivo complementario y no como prueba de causalidad.

3. Metodología

3.1. Datos y preparación

El archivo contiene 500.000 registros y 16 columnas. La ejecución final empleó 500.000 filas: 484.300 casos de permanencia y 15.700 abandonos. No se observaron registros duplicados. Varias variables presentaron alrededor de 2 % de valores faltantes, tratados dentro del preprocesamiento mediante imputación aprendida exclusivamente con el conjunto de entrenamiento.

La variable objetivo fue **abandono**. En el código revisado se excluyen **id_estudiante**, por ser un identificador, y las columnas constantes, como **tipo_institucion**. Las variables restantes incluyen sexo, edad, grado, zona geográfica, nacionalidad, pobreza, repetición, calificación, materias reprobadas, inasistencia, reportes disciplinarios e inseguridad en el plantel.

Los datos se dividieron de forma estratificada en 70 % para entrenamiento, 15 % para validación y 15 % para prueba. Los imputadores, escaladores y vocabularios categóricos se ajustaron únicamente con entrenamiento para evitar fuga de información. Las variables numéricas se estandarizaron; las categóricas se representaron mediante embeddings aprendidos.

3.2. Arquitecturas

El modelo Multilayer Perceptron (MLP) funciona como línea base por su capacidad para aprender relaciones no lineales en datos tabulares. Cada una de las ocho variables numéricas se proyecta a un vector de dimensión 32 y cada una de las cinco variables categóricas se transforma mediante un embedding de igual dimensión. Los

trece vectores se concatenan en una representación de 416 componentes, procesada por capas densas de 128, 64 y 32 unidades con activación ReLU. Se aplican Batch Normalization y dropout de 0,30 y 0,20 antes de una salida sigmoidal. La MLP contiene 65.761 parámetros.

El segundo modelo interpreta cada variable como un token de dimensión 32 y aplica Multi-Head Self-Attention. Para una cabeza, la operación se expresa como

$$\text{Att}(Q, K, V) = \text{softmax} \left(\frac{QK^\top}{\sqrt{d_k}} \right) V, \quad (1)$$

donde Q , K y V son proyecciones aprendidas de los tokens. Se utilizaron cuatro cabezas con subespacios de dimensión ocho. La salida se combina mediante una conexión residual y Layer Normalization, seguida de una red feed-forward que proyecta cada token de 32 a 64 componentes y nuevamente a 32. Una segunda conexión residual, Global Average Pooling y una capa densa de 64 unidades preceden a la salida sigmoidal. El Self-Attention model contiene 12.225 parámetros.

En el *forward pass*, ambas arquitecturas convierten primero cada predictor en un vector de 32 dimensiones. La MLP concatena los vectores y los procesa de forma directa; el Self-Attention model permite que cada variable consulte a las demás mediante Q , K y V , resume los tokens y realiza la clasificación. Esta comparación permite evaluar si el modelado explícito de interacciones aporta una mejora frente a una línea base densa.

3.3. Entrenamiento y evaluación

Ambos modelos utilizaron entropía cruzada binaria, Adam, dropout, reducción adaptativa de la tasa de aprendizaje y parada temprana monitoreando PR-AUC de validación. Para compensar el desbalance se aplicaron pesos de clase: los errores sobre abandono recibieron un peso mayor.

Cada modelo produjo una probabilidad. El umbral no se fijó automáticamente en 0,50, sino que se seleccionó exclusivamente sobre validación maximizando F1. El conjunto de prueba permaneció aislado hasta la evaluación final. Se reportaron PR-AUC, ROC-AUC, precision, recall, F1 y matriz de confusión.

La MLP alcanzó su mejor PR-AUC de validación en la época 18, con 0,8039. El entrenamiento se detuvo en la época 22 y restauró esos pesos. El Self-Attention model alcanzó su mejor valor en la época 5, con 0,7989, y se detuvo en la época 9. La reducción de la tasa de aprendizaje y la parada temprana evitaron continuar cuando la mejora dejó de ser sostenida.

La pérdida de entrenamiento no se compara de manera literal con la pérdida de validación: los pesos de clase y dropout actúan durante entrenamiento, mientras la validación se calcula bajo condiciones diferentes. Por ello, una pérdida de validación inferior a la de entrenamiento no implica por sí sola un error metodológico.

4. Resultados

La Tabla 1 presenta la evaluación final sobre 75.000 registros de prueba, con 2.355 casos positivos. La MLP obtuvo el mayor PR-AUC, recall y F1.

Cuadro 1: Resultados finales sobre el conjunto de prueba.

Modelo	Umbral	Prec.	Recall	F1	PR-AUC	ROC-AUC
MLP	0,9197	0,8103	0,7707	0,7900	0,8064	0,9486
Self-Attention	0,9515	0,8051	0,7682	0,7862	0,8036	0,9491

La MLP detectó 1.815 de los 2.355 abandonos: produjo 540 falsos negativos y 425 falsas alertas. El modelo con Self-Attention detectó 1.809 abandonos, dejó 546 falsos negativos y produjo 438 falsas alertas. En consecuencia, Self-Attention redujo el recall en 0,25 puntos porcentuales y el F1 en 0,38 puntos respecto de la MLP.

La Figura 2 muestra resultados muy cercanos. La diferencia absoluta en PR-AUC es 0,0028 a favor de la MLP. El Self-Attention model supera a la MLP en ROC-AUC por apenas 0,0005, pero esa ventaja no se refleja en recall, F1 ni en el número de errores al aplicar el umbral seleccionado. En términos operativos, la MLP detecta seis abandonos adicionales y produce trece falsas alertas menos.

La inasistencia anual recibió el mayor peso medio de Self-Attention (0,0861). Sin embargo, los demás pesos estuvieron muy cerca del valor uniforme de $1/13 \approx 0,0769$, por lo que no apareció una jerarquía fuerte. El identificador y la columna constante fueron excluidos antes del entrenamiento; la interpretación se realiza sobre las 13 variables válidas.

5. Discusión

Los resultados responden negativamente a la pregunta de investigación: el modelo con Self-Attention no mejoró la línea base. La MLP logró mejor recall y F1 con menor complejidad estructural, aunque contiene más parámetros. Este hallazgo demuestra que añadir un mecanismo especializado de Self-Attention no garantiza una mejora en datos tabulares.


La accuracy cercana a 98,7 % debe interpretarse con cautela porque la clase mayoritaria por sí sola representa 96,86 % de los registros. La evidencia más relevante es el PR-AUC cercano a 0,80, claramente superior a la prevalencia positiva de 0,0314, junto con precision próxima a 0,81 y recall alrededor de 0,77. El desempeño es prometedor, pero la MLP todavía deja sin detectar 540 abandonos en prueba.

Las diferencias entre arquitecturas son pequeñas y proceden de una sola semilla, por lo que no se afirma significancia estadística. Antes de un uso real se requiere comprobar calibración, estabilidad temporal y desempeño por sexo, nacionalidad, zona y nivel de pobreza. También se necesita validación con cohortes futuras e instituciones no observadas durante el entrenamiento.


Control de calidad. La ejecución final utilizó los 500.000 registros. Se excluyeron `id_estudiante` y la columna constante `tipo_institucion` antes de dividir y entrenar los modelos.

6. Limitaciones


No se dispone de una partición temporal ni por institución y la ejecución final utilizó una sola semilla. El origen real, anonimizado o sintético del dataset debe docu-




(a) Training loss y validation loss de la MLP.



(b) PR-AUC de entrenamiento y validación de la MLP.



(c) Training loss y validation loss del Self-Attention model.



(d) PR-AUC de entrenamiento y validación del Self-Attention model.

Figura 1: Evolución del entrenamiento. La MLP mejora de forma gradual, mientras el Self-Attention model alcanza antes una meseta.




Figura 2: Comparación de las métricas finales de ambos modelos.

mentarse. Tampoco se evaluaron calibración ni métricas de equidad por subgrupos. Los pesos de Self-Attention describen asociaciones internas del modelo, no relaciones causales ni efectos de una posible intervención.

7. Conclusiones

La MLP fue el mejor modelo de la evaluación final, con PR-AUC de 0,8064, recall de 0,7707 y F1 de 0,7900. El modelo con Self-Attention no aportó una mejora y generó más falsos negativos. Por parsimonia y rendimiento, la MLP constituye la opción recomendada.

El modelo debe emplearse como apoyo analítico y nunca como mecanismo autónomo para clasificar o sancionar estudiantes. Como trabajo futuro se propone repetir el experimento con varias semillas, validar por cohorte temporal, estudiar calibración y comparar con modelos tabulares no neuronales.




Figura 3: Peso promedio de Self-Attention por variable en la evaluación final.